


머신러닝 특성 공학(Feature Engineering) 파이프라인

Titanic 생존 예측 — 전처리·변수 선택 전략 비교 분석



이름	천지운 (학번 2023676)
과목	데이터 엔지니어링 / 머신러닝
데이터셋	Titanic Dataset (891 samples, 12 columns)
과제	Feature Engineering Pipeline 설계 및 성능 비교
모델	Logistic Regression · RandomForest · XGBoost · LightGBM
GitHub	https://github.com/jiun3374/titanic-feature-engineering

STEP 01. 데이터 준비

본 과제는 Kaggle Titanic 데이터셋을 사용하여 승객의 생존 여부(Survived)를 예측하는 이진 분류(Binary Classification) 문제이다. 데이터는 수치형과 범주형 변수가 혼합되어 있으며, 결측치를 포함하고 있어 특성 공학 실습에 적합하다.

데이터 형태(shape): 891 rows × 12 columns (요구 조건인 500개 이상 샘플 충족)

주요 컬럼 설명


컬럼	타입	설명
Survived	수치(타겟)	생존 여부 (0=사망, 1=생존)
Pclass	범주	객실 등급 (1/2/3등석)
Sex	범주	성별
Age	수치	나이 (결측 19.9%)
SibSp / Parch	수치	동승 형제·배우자 / 부모·자녀 수
Fare	수치	운임 요금
Embarked	범주	탑승 항구 (C/Q/S, 결측 0.2%)
Cabin	범주	객실 번호 (결측 77.1%)

타겟 분포: 사망 549명 vs 생존 342명 → 생존율 약 38.4%. 다소 불균형하나 심각한 수준은 아니다.

STEP 02. 탐색적 데이터 분석 (EDA)

결측치 비율 분석


컬럼	결측 비율
Age	19.87%
Cabin	77.1%
Embarked	0.22%




[그림 1] 컬럼별 결측치 비율

Cabin은 결측이 77%로 과도하여 사용하지 않으며, Age(19.9%)는 대표값 대체, Embarked(0.2%)는 최빈값으로 처리한다.

변수 분포 및 이상치




[그림 2] 수치형 변수 분포 (Histogram)



[그림 3] Fare·Age Boxplot — 이상치 확인


IQR 기준 이상치는 Fare 116건, Age 11건이다. 특히 Fare는 고가 운임 승객으로 인한 우편향 분포를 보이며, 이상치에 강건한 RobustScaler 실험의 동기가 된다.

상관관계 및 타겟 분석



[그림 4] 수치형 변수 상관관계 Heatmap

Pclass와 Survived는 음의 상관(-0.34)을 보여 등급이 높을수록(숫자가 작을수록) 생존율이 높다. Fare는 양의 상관(0.26)을 가진다.



[그림 5] 타겟 분포 및 성별·등급별 생존 (Countplot)

EDA 요약: ① 데이터 품질 문제 — Cabin 고결측, Fare 이상치. ② 불균형 — 생존율 38%로 경미. ③ 주요 변수 — 성별(여성 생존율 압도적), 객실 등급, 운임이 생존과 강하게 연관.

STEP 03. 특성 공학 파이프라인

결측치 처리·인코딩·스케일링 각각에 대해 2가지 이상의 전략을 실험에 반영하였고, 파생 변수 4종을 생성하였다.

구분	적용 전략 (비교 실험에 반영)
결측치 처리	Mean / Median / Most-Frequent Imputation, Drop NA
범주형 인코딩	Label Encoding ↔ One-Hot Encoding
스케일링	StandardScaler / MinMaxScaler / RobustScaler


파생 변수 생성 (필수 2개 이상 → 4개 생성)

파생 변수	정의	의도
FamilySize	SibSp + Parch + 1	동반 가족 규모
IsAlone	FamilySize == 1	단독 탑승 여부
Title	이름에서 호칭 추출(Mr/Mrs/Miss/Rare)	사회적 지위·성별·연령 대리
FarePerPerson	Fare / FamilySize	1인당 실질 운임

Title은 EDA에서 가장 강력한 파생 변수로 확인되며, FarePerPerson은 가족 단위 합산 운임을 1인 기준으로 정규화하여 Fare 단독보다 변별력이 높다.

STEP 04. 변수 선택 (Feature Selection)

Random Forest Feature Importance와 SelectKBest(ANOVA F-test) 두 방법을 사용하였다. 전체 변수와 상위 8개 변수만 사용한 경우의 성능을 비교한다.



[그림 6] Random Forest 변수 중요도 (상위 15)

상위 5개 변수: Age (0.2013), FarePerPerson (0.1451), Fare (0.1362), Title_Mr (0.0968), Sex_female (0.0919)

변수 집합	변수 수	F1-score
전체 변수	21	0.7704
상위 8개	8	0.7669

상위 8개 변수만으로도 F1 0.7669를 달성하여 전체(0.7704) 대비 거의 동등한 성능을 유지한다. 변수 수를 21→8개로 줄여 모델을 단순화하면서 과적합 위험을 낮추는 효과를 확인할 수 있다.

STEP 05. 모델 학습 및 실험 비교

4가지 모델(LogReg, RandomForest, XGBoost, LightGBM)을 학습하고, 과제에서 지정한 4가지 전처리 조합(Base / Exp-1 / Exp-2 / Exp-3)에 대해 성능을 비교하였다. 각 실험에서 가장 높은 F1을 기록한 모델 기준으로 정리한다.

실험	결측치	인코딩	스케일링	FSel	Best Model	Acc	F1	ROC-AUC
Base	없음	Label	없음	X	RandomForest	0.8101	0.7536	0.8287
Exp-1	Mean	One-Hot	Standard	X	LogReg	0.8492	0.7939	0.8792
Exp-2	Median	Label	MinMax	O	RandomForest	0.8101	0.7536	0.8298
Exp-3	Most-Freq	One-Hot	Robust	O	LightGBM	0.7933	0.7338	0.8245

최고 성능: Exp-1 (LogReg, F1=0.7939). 강조 표시된 행이 전체 실험 중 최고 조합이다.

Exp-1 모델별 상세 성능

Model	Accuracy	Precision	Recall	F1	ROC-AUC
LogReg	0.8492	0.8387	0.7536	0.7939	0.8792
RandomForest	0.8101	0.7612	0.7391	0.75	0.8196
XGBoost	0.8268	0.7969	0.7391	0.7669	0.837
LightGBM	0.8101	0.7536	0.7536	0.7536	0.8262

추가 분석 (가산점 항목)


Pipeline 객체 구성, GridSearchCV 하이퍼파라미터 튜닝, SHAP 기반 설명가능성 분석, Feature Importance 시각화를 추가로 수행하였다.

GridSearchCV 하이퍼파라미터 튜닝

RandomForest에 대해 5-fold 교차검증 그리드 탐색을 수행하였다.

항목	값
Best Params	{'max_depth': 6, 'min_samples_split': 5, 'n_estimators': 200}
CV Best F1	0.741
Test Accuracy	0.7989
Test F1	0.7143

SHAP 기반 설명가능성 분석



[그림 7] SHAP Summary Plot — 변수별 예측 기여도

SHAP 분석 결과 Title(호칭), 성별(Sex), FarePerPerson이 생존 예측에 가장 큰 영향을 미친다. 여성(Sex_female=1)과 높은 1인당 운임은 생존 확률을 끌어올리는 방향으로 작용하여, EDA 및 변수 중요도 분석과 일관된 결과를 보인다.

최종 결론

Q. 어떤 전처리 전략이 가장 효과적이었나?

One-Hot Encoding + StandardScaler 조합(Exp-1)이 F1 0.7939로 가장 우수했다. 특히 선형 모델(LogReg)에서 인코딩·스케일링의 효과가 두드러졌다.

Q. One-Hot Encoding이 항상 좋은가?

그렇지 않다. 트리 기반 모델(RF/XGB/LGBM)은 Label Encoding에서도 견고한 성능을 내며, One-Hot의 이점은 주로 거리·계수 기반 선형 모델에서 나타났다.

Q. Feature Selection이 과적합 감소에 기여했나?

변수를 21→8개로 줄여도 F1이 0.7704→0.7669로 거의 유지되어, 모델 단순화와 과적합 위험 완화 효과를 확인했다.

Q. 스케일링이 모델별로 어떤 영향을 미쳤나?

선형 모델은 스케일링에 민감하여 성능이 크게 향상된 반면, 트리 기반 모델은 스케일에 거의 영향받지 않았다. 모델 특성에 맞춘 전처리 선택이 중요하다.

Q. Feature Engineering이 성능 향상에 얼마나 기여했나?

전처리를 최소화한 Base 대비, 파생 변수와 전처리를 적용한 Exp-1에서 F1이 0.7536→0.7939로 향상되어, 특성 공학이 실제 성능 개선에 기여함을 정량적으로 확인했다.

본 과제를 통해 동일한 알고리즘이라도 전처리·인코딩·스케일링·변수 선택 전략에 따라 성능이 달라짐을 실험적으로 검증하였으며, 모델 특성에 맞는 특성 공학 설계의 중요성을 확인하였다.